ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

BÁO CÁO BÀI TẬP TUẦN 4

Học phần: Khai phá và Phân tích Dữ liệu (AIT3003)

Họ và tên: Nguyễn Hải Nam
Mã sinh viên: 23021870

Chủ đề: Bài tập 4: Phân cụm dữ liệu (Data Clustering)

---

1. Bài P1: Tính Cell-based Entropy đánh giá xu hướng phân cụm

Cho tập dữ liệu gồm $n = 8$ điểm phân bố trong lưới không gian kích thước 4×4 ($m = 16$ ô).

a. Xác định phân bố các điểm dữ liệu trên các ô lưới

Quan sát vị trí các điểm trên hình vẽ:

- Hàng 1 (trên cùng): Ô $(1, 4)$ chứa 2 điểm dữ liệu; các ô còn lại chứa 0 điểm.
- Hàng 2: Tất cả 4 ô đều chứa 0 điểm dữ liệu.
- Hàng 3: Ô $(3, 1)$ chứa 4 điểm dữ liệu; các ô còn lại chứa 0 điểm.
- Hàng 4 (dưới cùng): Ô $(4, 3)$ chứa 2 điểm dữ liệu; các ô còn lại chứa 0 điểm.

Tổng số điểm kiểm tra: $2 + 4 + 2 = 8$ điểm. Xác suất thực nghiệm $p_i = \frac{c_i}{n}$ tại các ô:

- 1 ô chứa 4 điểm: $p_1 = \frac{4}{8} = 0.5$.
- 2 ô chứa 2 điểm: $p_2 = p_3 = \frac{2}{8} = 0.25$.
- 13 ô chứa 0 điểm: $p_i = 0$ (cho đóng góp vào entropy bằng 0).

b. Tính toán giá trị Entropy H

Áp dụng công thức tính Cell-based Entropy:

$$H = -\sum_{i=1}^{16} p_i \log_2(p_i) = -\left[1 \times (0.5 \log_2 0.5) + 2 \times (0.25 \log_2 0.25)\right]$$
$$= -\left[0.5 \times (-1) + 0.5 \times (-2)\right] = -\left[-0.5 - 1.0\right] = \mathbf{1.5}(\text{bits})$$

Đánh giá: Với $m = 16$ ô, entropy cực đại là $H_{\max} = \log_2(16) = 4$. Entropy chuẩn hóa $H_{\text{norm}} = \frac{1.5}{4} = \mathbf{0.375} \ll 1.0$, chứng minh tập dữ liệu có xu hướng co cụm (clustering tendency) rất mạnh.

2. Bài P2: Phân cụm phân hoạch bằng thuật toán K-Means

Tập gồm 8 điểm: $A1(2,10), A2(2,5), A3(8,4), B1(5,8), B2(7,5), B3(6,4), C1(1,2), C2(4,9)$.
Khởi tạo 3 tâm cụm ban đầu ($k=3$):

$$\boldsymbol{\mu}_1^{(0)} = A1(2,10), \quad \boldsymbol{\mu}_2^{(0)} = B1(5,8), \quad \boldsymbol{\mu}_3^{(0)} = C1(1,2)$$

a. Vòng lặp 1 và xác định 3 tâm cụm mới

Tính khoảng cách bình phương Euclidean $d^2(\mathbf{x}, \boldsymbol{\mu}_i) = (x - \mu_{ix})^2 + (y - \mu_{iy})^2$:

- $A1(2,10)$: $d^2 = [0, 13, 65] \implies$ gán C_1.
- $A2(2,5)$: $d^2 = [25, 18, 10] \implies$ gán C_3.
- $A3(8,4)$: $d^2 = [72, 25, 53] \implies$ gán C_2.
- $B1(5,8)$: $d^2 = [13, 0, 52] \implies$ gán C_2.
- $B2(7,5)$: $d^2 = [50, 13, 45] \implies$ gán C_2.
- $B3(6,4)$: $d^2 = [52, 17, 29] \implies$ gán C_2.
- $C1(1,2)$: $d^2 = [65, 52, 0] \implies$ gán C_3.
- $C2(4,9)$: $d^2 = [5, 2, 58] \implies$ gán C_2 (do $2 < 5$).

Kết quả gán cụm vòng 1: $C_1 = \{A1\}$, $C_2 = \{A3, B1, B2, B3, C2\}$, $C_3 = \{A2, C1\}$.
Ba tâm cụm sau vòng thực thi đầu tiên ($\boldsymbol{\mu}^{(1)}$):

$$\boldsymbol{\mu}_1^{(1)} = A1 = (\mathbf{2}, \mathbf{10})$$
$$\boldsymbol{\mu}_2^{(1)} = \left(\frac{8+5+7+6+4}{5}, \frac{4+8+5+4+9}{5}\right) = \left(\frac{30}{5}, \frac{30}{5}\right) = (\mathbf{6}, \mathbf{6})$$
$$\boldsymbol{\mu}_3^{(1)} = \left(\frac{2+1}{2}, \frac{5+2}{2}\right) = \left(\frac{3}{2}, \frac{7}{2}\right) = (\mathbf{1.5}, \mathbf{3.5})$$

b. Quá trình lặp và ba cụm cuối cùng

- **Vòng 2:** Với các tâm $(2,10), (6,6), (1.5, 3.5)$, điểm $C2$ đổi sang C_1 vì $d^2(C2, \boldsymbol{\mu}_1) = 5 < d^2(C2, \boldsymbol{\mu}_2) = 13$. Các cụm mới: $C_1 = \{A1, C2\}$, $C_2 = \{A3, B1, B2, B3\}$, $C_3 = \{A2, C1\}$.
  Tâm mới: $\boldsymbol{\mu}_1^{(2)} = (3, 9.5)$, $\boldsymbol{\mu}_2^{(2)} = (6.5, 5.25)$, $\boldsymbol{\mu}_3^{(2)} = (1.5, 3.5)$.
- **Vòng 3:** Với các tâm mới, điểm $B1$ đổi sang C_1 do $d^2(B1, \boldsymbol{\mu}_1) = 6.25 < d^2(B1, \boldsymbol{\mu}_2) = 9.8125$. Các cụm mới: $C_1 = \{A1, B1, C2\}$, $C_2 = \{A3, B2, B3\}$, $C_3 = \{A2, C1\}$.
  Tâm mới: $\boldsymbol{\mu}_1^{(3)} = (\frac{11}{3}, 9) \approx (3.67, 9)$, $\boldsymbol{\mu}_2^{(3)} = (7, \frac{13}{3}) \approx (7, 4.33)$, $\boldsymbol{\mu}_3^{(3)} = (1.5, 3.5)$.
- **Vòng 4:** Gán lại cụm theo $\boldsymbol{\mu}^{(3)}$ không làm thay đổi vị trí của điểm nào $\implies$ Thuật toán hội tụ.

Ba cụm cuối cùng thu được:

- $\mathbf{C_1} = \{\mathbf{A1}(\mathbf{2}, \mathbf{10}), \mathbf{B1}(\mathbf{5}, \mathbf{8}), \mathbf{C2}(\mathbf{4}, \mathbf{9})\}$
- $\mathbf{C_2} = \{\mathbf{A3}(\mathbf{8}, \mathbf{4}), \mathbf{B2}(\mathbf{7}, \mathbf{5}), \mathbf{B3}(\mathbf{6}, \mathbf{4})\}$
- $\mathbf{C_3} = \{\mathbf{A2}(\mathbf{2}, \mathbf{5}), \mathbf{C1}(\mathbf{1}, \mathbf{2})\}$

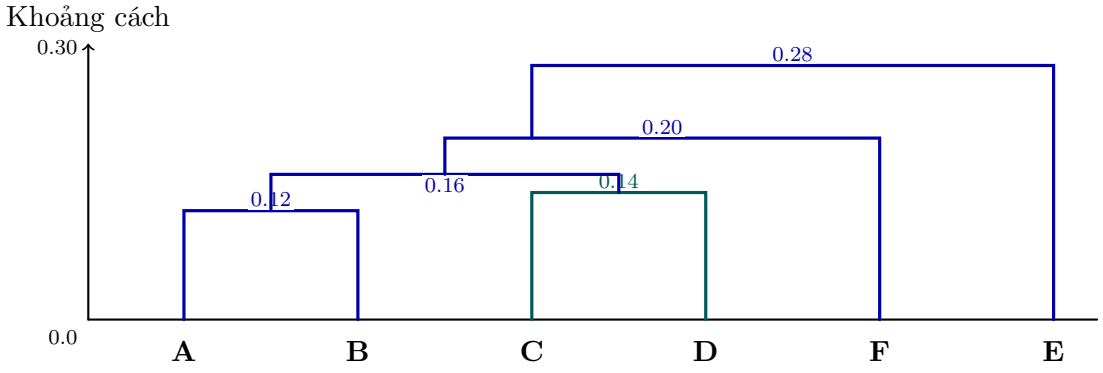
3. Bài P3: Phân cụm phân cấp (Hierarchical Clustering)

Cho ma trận khoảng cách giữa 6 đối tượng:

	A	**B**	**C**	**D**	**E**	**F**
A	0					
B	0.12	0				
C	0.51	0.25	0			
D	0.84	0.16	0.14	0		
E	0.28	0.77	0.70	0.45	0	
F	0.34	0.61	0.93	0.20	0.67	0

a. Liên kết đơn (Single Link: $\delta(C_i, C_j) = \min\{d(x, y)\}$)

- **Bước 1:** Khoảng cách nhỏ nhất $d(A, B) = 0.12 \implies$ Gộp **(AB)** ở mức **0.12**.
- **Bước 2:** $d(C, D) = 0.14 \implies$ Gộp **(CD)** ở mức **0.14**.
- **Bước 3:** $d(AB, CD) = \min(0.51, 0.25, 0.84, 0.16) = 0.16 \implies$ Gộp **(ABCD)** ở mức **0.16**.
- **Bước 4:** $d(ABCD, F) = \min(d(AB, F), d(CD, F)) = \min(0.34, 0.20) = 0.20 \implies$ Gộp **(ABCDF)** ở mức **0.20**.
- **Bước 5:** $d(ABCDF, E) = \min(d(ABCD, E), d(F, E)) = \min(0.28, 0.67) = 0.28 \implies$ Gộp với **E** ở mức **0.28**.

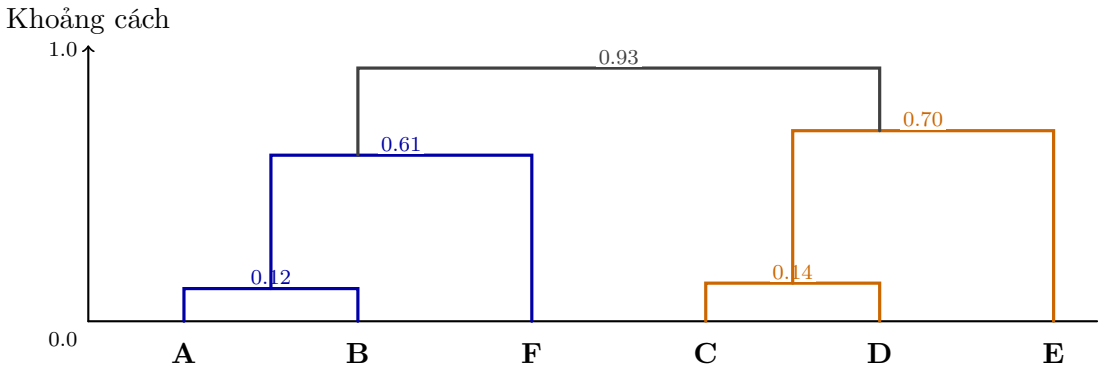


Hình 1: Dendrogram phân cụm phân cấp với Single Link

b. Liên kết hoàn chỉnh (Complete Link: $\delta(C_i, C_j) = \max\{d(x, y)\}$)

- **Bước 1:** Khoảng cách nhỏ nhất $d(A, B) = 0.12 \implies$ Gộp **(AB)** ở mức **0.12**.
- **Bước 2:** $d(C, D) = 0.14 \implies$ Gộp **(CD)** ở mức **0.14**.
- **Bước 3:** Các khoảng cách cụm: $d(AB, F) = \max(0.34, 0.61) = 0.61$, $d(CD, E) = \max(0.70, 0.45) = 0.70$, $d(E, F) = 0.67$. Nhỏ nhất là $d(AB, F) = 0.61 \implies$ Gộp **(ABF)** ở mức **0.61**.

- **Bước 4:** $d(CD, E) = 0.70 \implies$ Gộp **(CDE)** ở mức **0.70**.
- **Bước 5:** $d(ABF, CDE) = \max_{x\in\{A,B,F\}, y\in\{C,D,E\}} d(x, y) = d(C, F) = 0.93 \implies$ Gộp hai cụm lớn ở mức **0.93**.



Hình 2: Dendrogram phân cụm phân cấp với Complete Link