ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

BÁO CÁO BÀI TẬP TUẦN 2

Học phần: Khai phá và Phân tích Dữ liệu (AIT3003)

Họ và tên: *[Nguyễn Hải Nam]*
Mã sinh viên: *[23021870]*
Chủ đề: Tuần 2: Tiền xử lý và Chuẩn bị dữ liệu (Data Preparation)

---

1. Bài 1: Các phương pháp xử lý giá trị bị thiếu (Missing Values)

Trong khai phá dữ liệu thực tế, các bộ dữ liệu bị khuyết thuộc tính có thể được xử lý qua 6 phương pháp chính:

1. **Loại bỏ bộ dữ liệu (Ignore Tuple):** Bỏ dòng chứa giá trị khuyết. Phù hợp nhất khi nhãn lớp (*class label*) bị thiếu trong bài toán phân loại. Nhược điểm: Gây lãng phí các thông tin hợp lệ khác trong cùng một bản ghi.
2. **Điền thủ công (Manual Imputation):** Chuyên gia tra cứu và nhập liệu thủ công. Phương pháp này chính xác nhưng tốn thời gian, không khả thi với dữ liệu lớn.
3. **Thay thế bằng hằng số toàn cục (Global Constant):** Gán giá trị như `"Unknown"` hoặc mã riêng biệt. Nhược điểm: Có thể làm thuật toán nhầm lẫn đây là một nhóm đối tượng đặc biệt.
4. **Dùng thước đo xu hướng trung tâm (Central Tendency):** Điền bằng giá trị trung bình (*Mean*) với dữ liệu phân phối chuẩn, hoặc trung vị (*Median*) với dữ liệu phân phối lệch; dùng *Mode* cho thuộc tính định danh.
5. **Điền theo phân lớp (Class-Conditional Mean/Median):** Sử dụng giá trị trung bình/trung vị của thuộc tính trong cùng một lớp đối tượng với bản ghi đang xét.
6. **Ước lượng bằng giá trị có xác suất cao nhất (Most Probable Value):** Sử dụng các mô hình dự đoán (Hồi quy, Suy diễn Bayes, Cây quyết định) để dự báo giá trị khuyết dựa trên các thuộc tính còn lại.

2. Bài 2: Làm trơn dữ liệu bằng Binning & Phát hiện ngoại lệ

Cho tập dữ liệu độ tuổi ($n = 27$): {13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33, 35, 35, 35, 35, 3

a. Làm trơn bằng trung bình phân đoạn (Bin Depth = 3)

Chia đều 27 phần tử vào 9 bin, mỗi bin chứa 3 phần tử:

Nhận xét: Kỹ thuật giúp triệt tiêu dao động ngẫu nhiên nhưng làm mất chi tiết cá thể. Giá trị cực trị 70 ở Bin 9 bị kéo giảm đáng kể về 56.00.

Bin	Giá trị ban đầu	Trung bình Bin	Giá trị sau làm trơn
1	13, 15, 16	$44/3 \approx 14.67$	14.67, 14.67, 14.67
2	16, 19, 20	$55/3 \approx 18.33$	18.33, 18.33, 18.33
3	20, 21, 22	$63/3 = 21.00$	21.00, 21.00, 21.00
4	22, 25, 25	$72/3 = 24.00$	24.00, 24.00, 24.00
5	25, 25, 30	$80/3 \approx 26.67$	26.67, 26.67, 26.67
6	33, 33, 35	$101/3 \approx 33.67$	33.67, 33.67, 33.67
7	35, 35, 35	$105/3 = 35.00$	35.00, 35.00, 35.00
8	36, 40, 45	$121/3 \approx 40.33$	40.33, 40.33, 40.33
9	46, 52, 70	$168/3 = 56.00$	56.00, 56.00, 56.00

b. Phát hiện ngoại lai (Outliers)

Áp dụng quy tắc $1.5 \times$ IQR: Với $Q_1 = 20, Q_3 = 35 \implies \text{IQR} = 15$.

$$\text{Ngưỡng trên} = Q_3 + 1.5 \times \text{IQR} = 35 + 1.5(15) = 57.5$$

Do $70 > 57.5$, giá trị **70 là một điểm ngoại lai (Outlier)**.

c. Các phương pháp làm trơn khác

Bao gồm: Làm trơn bằng trung vị phân đoạn (*Bin Medians*), làm trơn bằng biên phân đoạn (*Bin Boundaries*), mô hình Hồi quy (*Regression*), và Phân cụm (*Clustering*).

3. Bài 3: Các thách thức trong tích hợp dữ liệu (Data Integration)

- **Định danh thực thể (Entity Identification):** Khớp các thuộc tính tương đương giữa các cơ sở dữ liệu dựa trên *Metadata* (tên trường, kiểu dữ liệu, ràng buộc).
- **Dư thừa dữ liệu (Redundancy):** Một thuộc tính có thể suy ra từ thuộc tính khác; sử dụng kiểm định χ^2 hoặc Pearson để phát hiện và loại bỏ.
- **Trùng lặp bản ghi (Tuple Duplication):** Nhận diện và hợp nhất các bản ghi trùng lặp phản ánh cùng một thực thể ngoài đời thực.
- **Xung đột giá trị dữ liệu (Value Conflicts):** Xử lý sự khác biệt về đơn vị đo lường (kg vs lb), định dạng biểu diễn, và thang đo.

4. Bài 4: Miền giá trị của các phương pháp chuẩn hóa

Phương pháp	Công thức	Miền giá trị sau chuẩn hó
Min-max normalization	$v' = \frac{v - \min}{\max - \min}(\text{new_max} - \text{new_min}) + \text{new_min}$	$[\text{new_min}, \text{new_max}]$ (thường [
Z-score normalization	$z = \frac{v - \bar{x}}{\sigma}$	$(-\infty, +\infty)$
Z-score (dùng MAD)	$z_{\text{MAD}} = \frac{v - \bar{x}}{\text{MAD}}$	$(-\infty, +\infty)$
Decimal scaling	$v' = \frac{v}{10^j}$	$(-1.0, 1.0)$

5. Bài 5: Chuẩn hóa giá trị tuổi $v = 35$

Tập dữ liệu có: min $= 13$, max $= 70$, $\bar{x} \approx 29.963$, độ lệch chuẩn $\sigma = 12.94$.

- **Min-max về** $[0, 1]$**:** $v' = \frac{35-13}{70-13} = \frac{22}{57} \approx \mathbf{0.3860}$.
- **Z-score normalization:** $z = \frac{35-29.963}{12.94} \approx \mathbf{0.3893}$.
- **Decimal scaling:** Do $\max(|v|) = 70$, chọn $j = 2 \implies v' = \frac{35}{10^2} = \mathbf{0.3500}$.

Đánh giá lựa chọn: Z-score normalization là phương pháp phù hợp nhất vì không bị bóp méo cục bộ bởi điểm ngoại lai 70 như Min-max, đồng thời phản ánh đúng độ phân tán của dữ liệu so với Decimal scaling.

6. Bài 6: Thuật toán tự động tạo phân cấp khái niệm

Nguyên lý: Thuộc tính chi tiết (lower level) có số lượng giá trị phân biệt (*distinct values*) lớn hơn thuộc tính tổng quát (higher level).

```
Algorithm: GenerateConceptHierarchy(D, NominalAttributes)
Input: Dataset D, tap thuoc tinh NominalAttributes
Output: Cay phan cap khai niem H

1. L = []
2. For each attribute A in NominalAttributes do:
3.     c = CountDistinctValues(D, A)
4.     Append (A, c) vao danh sach L
5. End For
6. Sap xep L giam dan theo c: L = [(A_1, c_1), ..., (A_k, c_k)]
7. Tao phan cap H: A_1 -> A_2 -> ... -> A_k
8. Return H
```

Ví dụ: Street (10,000) → City (500) → State (50) → Country (10).