ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

BÁO CÁO BÀI TẬP TUẦN 3

Học phần: Khai phá và Phân tích Dữ liệu (AIT3003)

Họ và tên: Nguyễn Hải Nam
Mã sinh viên: 23021870
Chủ đề: Tuần 3: Các độ đo tương tự và khoảng cách (Similarity measures)

---

1. Bài P1: Tính các khoảng cách cho vectơ số (Numeric Vectors)

Cho hai đối tượng trong không gian 4 chiều ($m = 4$):

$$\mathbf{x} = (22, 1, 42, 10), \quad \mathbf{y} = (20, 0, 36, 8)$$

Hiệu số trị tuyệt đối trên từng chiều: $|x_1 - y_1| = |22 - 20| = 2$, $|x_2 - y_2| = |1 - 0| = 1$, $|x_3 - y_3| = |42 - 36| = 6$, $|x_4 - y_4| = |10 - 8| = 2$.

a. Khoảng cách Euclidean (L_2 norm)

$$\begin{aligned} d_2(\mathbf{x}, \mathbf{y}) &= \sqrt{\sum_{i=1}^{4} |x_i - y_i|^2} \\ &= \sqrt{2^2 + 1^2 + 6^2 + 2^2} = \sqrt{4 + 1 + 36 + 4} \\ &= \sqrt{45} = 3\sqrt{5} \approx \mathbf{6.7082} \end{aligned}$$

b. Khoảng cách Manhattan (L_1 norm)

$$d_1(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^{4} |x_i - y_i| = 2 + 1 + 6 + 2 = \mathbf{11}$$

c. Khoảng cách Minkowski ($q = 3$)

$$\begin{aligned} d_3(\mathbf{x}, \mathbf{y}) &= \left(\sum_{i=1}^{4} |x_i - y_i|^3 \right)^{\frac{1}{3}} \\ &= \left(2^3 + 1^3 + 6^3 + 2^3\right)^{\frac{1}{3}} \\ &= (8 + 1 + 216 + 8)^{\frac{1}{3}} = \sqrt[3]{233} \approx \mathbf{6.1534} \end{aligned}$$

2. Bài P2: Độ tương tự Jaccard cho tập hợp từ (Set Similarity)

Xét hai câu dưới dạng các tập hợp từ phân biệt:

- Câu (a): $A = \{\text{ông, già, đi, nhanh, quá}\} \implies |A| = 5$
- Câu (b): $B = \{\text{thời, gian, trôi, đi, nhanh, quá}\} \implies |B| = 6$

Xác định tập giao và tập hợp của hai câu:

$$A \cap B = \{\text{đi, nhanh, quá}\}, \qquad |A \cap B| = 3$$
$$A \cup B = \{\text{ông, già, thời, gian, trôi, đi, nhanh, quá}\}, \qquad |A \cup B| = 8$$

Độ tương tự Jaccard:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{3}{8} = \mathbf{0.375}$$

Khoảng cách Jaccard tương ứng: $d_J(A, B) = 1 - J(A, B) = 1 - 0.375 = \mathbf{0.625}$.

3. Bài P3: Biểu diễn Vector và Độ tương tự Cosine (Cosine Similarity)

Xét hai câu văn bản sau khi chuẩn hóa chữ thường và lược bỏ dấu câu:

- (a) *"The sly fox jumped over the lazy dog"*.
- (b) *"The dog jumped at the intruder"*.

a. Xây dựng tập từ vựng và Vector tần suất (Term Frequency)

Tập từ vựng chung gồm $m = 9$ từ phân biệt:

$$V = \{\text{at, dog, fox, intruder, jumped, lazy, over, sly, the}\}$$

Vector biểu diễn tần suất từ của mỗi câu trên không gian từ vựng V:

$$\mathbf{x} = [0, 1, 1, 0, 1, 1, 1, 1, 2]$$
$$\mathbf{y} = [1, 1, 0, 1, 1, 0, 0, 0, 2]$$

b. Tính độ tương tự Cosine

- Tích vô hướng:

$$\begin{aligned}\mathbf{x} \cdot \mathbf{y} &= (0 \cdot 1) + (1 \cdot 1) + (1 \cdot 0) + (0 \cdot 1) \\ &\quad + (1 \cdot 1) + (1 \cdot 0) + (1 \cdot 0) + (1 \cdot 0) + (2 \cdot 2) \\ &= 1 + 1 + 4 = 6\end{aligned}$$

- Chuẩn Euclidean của các vector:

$$\|\mathbf{x}\| = \sqrt{0^2 + 1^2 + 1^2 + 0^2 + 1^2 + 1^2 + 1^2 + 1^2 + 2^2} = \sqrt{10}$$

$$\|\mathbf{y}\| = \sqrt{1^2 + 1^2 + 0^2 + 1^2 + 1^2 + 0^2 + 0^2 + 0^2 + 2^2} = \sqrt{8} = 2\sqrt{2}$$

Độ tương tự Cosine:

$$\begin{aligned}\cos\theta &= \frac{\mathbf{x}\cdot\mathbf{y}}{\|\mathbf{x}\|\|\mathbf{y}\|} = \frac{6}{\sqrt{10}\cdot\sqrt{8}} \\ &= \frac{6}{\sqrt{80}} = \frac{6}{4\sqrt{5}} = \frac{3}{2\sqrt{5}} \approx \mathbf{0.6708}\end{aligned}$$

Khoảng cách Cosine tương ứng: $d_{\text{cosine}} = 1 - \cos\theta \approx 1 - 0.6708 = \mathbf{0.3292}$.

4. Bài P4: Bảng quy hoạch động tính khoảng cách Levenshtein

So sánh hai chuỗi ký tự: Chuỗi nguồn S_1 = ‘‘`học sinh`’’ ($n = 8$) và chuỗi đích S_2 = ‘‘`hojc xih`’’ ($m = 8$), với chi phí các phép toán $w_{\text{del}} = w_{\text{ins}} = w_{\text{sub}} = 1$.

a. Bảng quy hoạch động (Levenshtein Distance Matrix)

Ký hiệu dấu cách được biểu diễn bằng ký tự ␣.

$S_1 \backslash S_2$	**ϵ**	**h**	**o**	**j**	**c**	**␣**	**x**	**i**	**h**
ϵ	0	1	2	3	4	5	6	7	8
h	1	0	1	2	3	4	5	6	7
ọ	2	1	1	2	3	4	5	6	7
c	3	2	2	2	2	3	4	5	6
␣	4	3	3	3	3	2	3	4	5
s	5	4	4	4	4	3	3	4	5
i	6	5	5	5	5	4	4	3	4
n	7	6	6	6	6	5	5	4	4
h	8	7	7	7	7	6	6	5	**4**

b. Kết quả và Chuỗi các thao tác biến đổi tối ưu

Khoảng cách Levenshtein giữa hai chuỗi là $D[8, 8] = \mathbf{4}$. Chuỗi 4 thao tác chỉnh sửa tối thiểu:

1. Giữ nguyên ký tự `'h'`.
2. Thay thế (*Substitute*) ký tự `'ọ'` bằng ký tự `'o'` (Chi phí: 1).
3. Chèn (*Insert*) ký tự `'j'` ngay sau `'o'` (Chi phí: 1).
4. Giữ nguyên ký tự `'c'` và dấu cách ␣.
5. Thay thế (*Substitute*) ký tự `'s'` bằng ký tự `'x'` (Chi phí: 1).
6. Giữ nguyên ký tự `'i'`.

7. Xóa (*Delete*) ký tự `'n'` (Chi phí: 1).
8. Giữ nguyên ký tự `'h'`.

$$\implies \text{Tổng chi phí biến đổi tối thiểu} = 1 + 1 + 1 + 1 = \mathbf{4}.$$